



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA



Departamento de Computación,
Facultad de Ciencias Exactas y Naturales,
Universidad de Buenos Aires

Trabajo Práctico 2

Bases de Datos

Primer Cuatrimestre de 2016

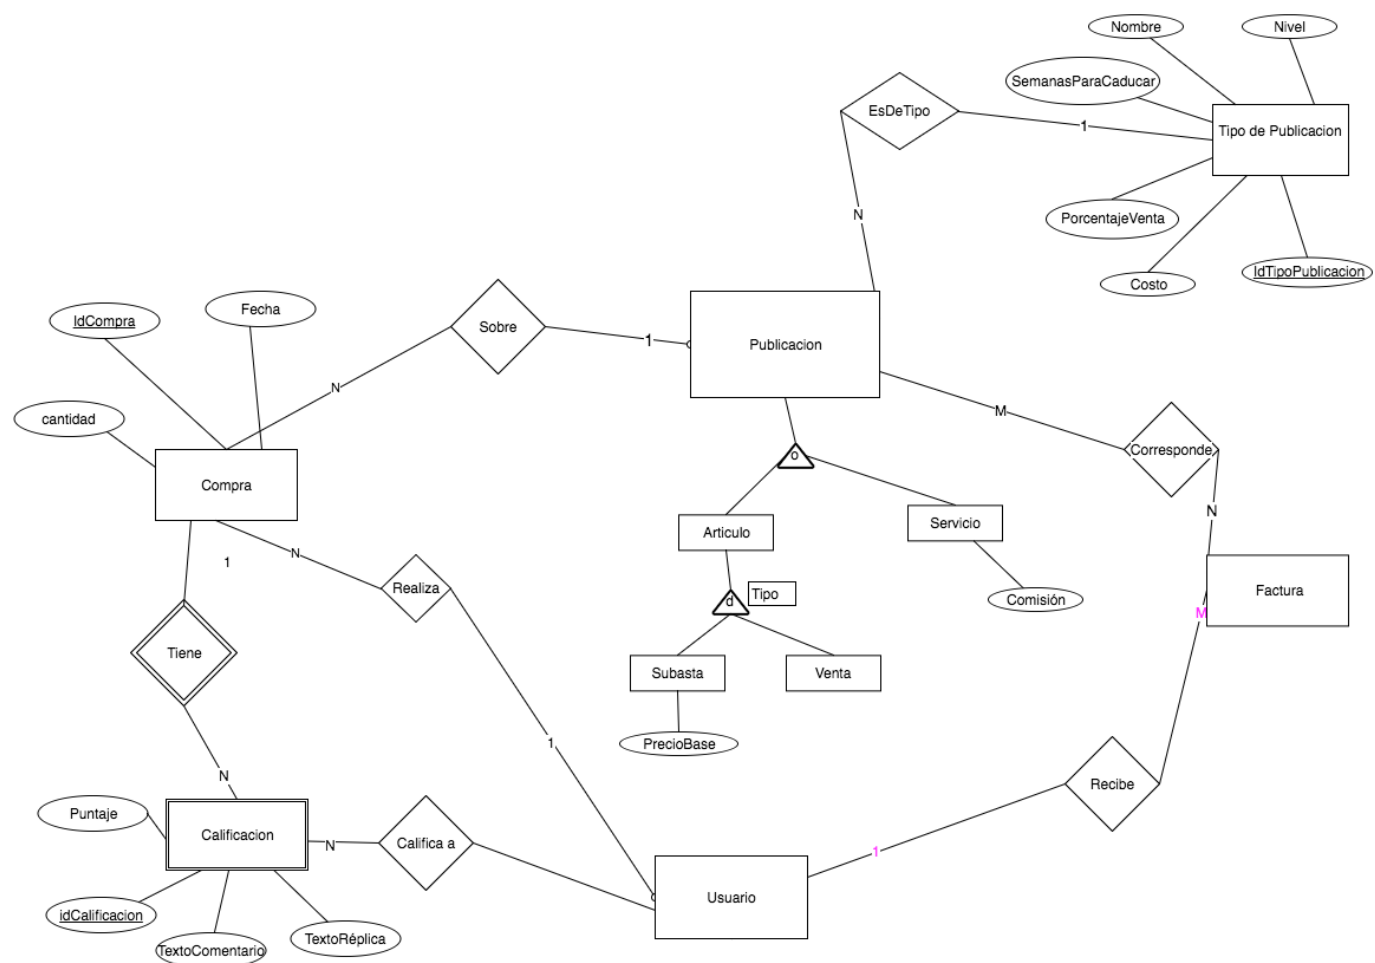
Apellido y Nombre	LU	E-mail
Federico Hosen	825/12	federico.hosen@gmail.com
Martin 'Martó' Caravario	470/12	martin.caravario@gmail.com
Guido Rajngewerc	379/12	guido.raj@gmail.com
Christian Russo	679/10	christian.russo8@gmail.com

1. Introducción

En el siguiente trabajo se desarrolla un modelo de Bases de Datos NoSQL con MongoDB teniendo en cuenta el problema descrito en el TP1. Para esto, se utilizó una sección del DER completo del TP1 y se diseñaron los documentos correspondientes para realizar las consultas pedidas en el enunciado del TP2.

2. Parte 1 - Diseño

2.1. Diagrama Entidad relacion



Las consultas pedidas solamente necesitan de usuarios, ventas, reputaciones, calificaciones, comisiones y facturas. Por lo tanto usamos:

- Para usuarios y ventas, las tablas de Usuarios, Publicaciones y Compra
- Para reputaciones de usuarios, las tablas de Calificación y Usuario
- Para comisiones, usamos las tablas de Publicación y Tipo de Publicación.
- Para monto de facturas, usamos las tabla de Facturas

2.2. Colecciones

A continuación, mostramos las colecciones que utilizamos para resolver las consultas propuestas en el enunciado

2.2.1. Publicaciones

```
1 {
2   "Id": 65,
3   "TipoPublicacion": "Servicio"
4 }
```

2.2.2. Compra

```
1 {
2   "idCompra": 656897,
3   "idUsuarioComprador": 65468,
4   "Fecha": "2-06-2014",
5   "Cantidad": 2,
6   "Publicacion": {
7     "idPublicacion": 2365,
8     "idUsuario": 123,
9     "Precio": 3655,
10    "PorcentajeVenta": 20 //entre 0 y 100
11  },
12   "CalificacionDelVendedor": 8,
13   "CalificacionDelComprador": 6
14 }
```

2.2.3. Factura

```
1 {
2   "idFactura": 687468,
3   "IdUsuario": 654,
4   "Fecha": "16-9-2015",
5   "TotalAPagar": 5624,
6   "estoyPagando": [
7     {
8       "idPublicacion": 54,
9       "TipoSuscripcion": "Rubi"
10    },
11    {
12       "idPublicacion": 54,
13       "TipoSuscripcion": "Libre"
14    }
15  ]
16 }
```

2.3. Migración datos SQL a Colecciones

Para migrar los datos de SQL (MySQLWorkwench) al formato de JSON que se necesita en MongoDB lo que hicimos fue exportar los datos directo desde MySQLWorkwench, pero estos se exportan en JSON plano, es decir no quedaba formateado de la forma que nosotros queríamos.

Para solucionar este problema, realizamos unos algoritmos en python para formatearlos a mano. Estos algoritmos reciben como input el JSON plano y devuelven un JSON formateado para MongoDB

2.3.1. Parser para el JSON de la compra

```
import json
from pprint import pprint

with open(raw_input()) as data_file:
    data = json.load(data_file)
for a in data:
    print "{"
    print '"idCompra": ' , a['idCompra'], ","
    print '"idUserario": ' , a['idUserario'],","
    print '"fecha": ' , ''',a['fecha'],'''',"
    print '"cantidad": ' , a['cantidad'],","
    print '"Publicacion": {'
    print '"idPublicacion": ' , a['idPublicacion'],","
    print '"idUserario": ' , a['idUserario'],","
    print '"Precio": ' , a['precio'],","
    print '"PorcentajeVenta": ' , a['porcentajeVenta']
    print "}" ,","
    print '"calificacionVendedor": ' , a['CalificacionDelVendedor'], ','
    print '"calificacionComprador": ' , a['CalificacionDelComprador'], ''
    print '}'
```

2.3.2. Parser para el JSON de la Factutra

```
import json
from pprint import pprint

with open('factura_sql.json') as data_file:
    data = json.load(data_file)

c = {}
for a in data:
    c.setdefault(a["idFactura"], []).append(a)

for a in c:
    print '{'
    print '"idFactura": ', c[a][0]['idFactura'], ","
    print '"IdUsuario": ', c[a][0]['idUsuario'], ","
    print '"Fecha": ', "'", c[a][0]['fecha'], "'", ","
    total = 0
    for x in c[a]:
        total = total + c[a][c[a].index(x)]['totalAPagar']
    print '"TotalAPagar": ', total, ","
    print '"estoyPagando": ['
    i = 1
    for x in c[a]:
        print "{"
        print '"idPublicacion": ', c[a][c[a].index(x)]['idPublicacion'], ","
        print '"TipoSuscripcion": ', "'", c[a][c[a].index(x)]['nombre'], "'"
        if i == len(c[a]):
            print "}"
        else:
            print "},"
        i = i+1
    print ']'
    print '}'
```

Nota: para la colección de publicaciones no tuvimos que hacer ningún algoritmo.

2.4. Consultas SQL

A continuación listamos las consultas realizadas para conseguir los datos necesarios para nuestras colecciones:

2.4.1. SQL de Publicaciones

```
select p.idPublicacion,
CASE
  when s.idPublicacion is not null and
    (v.idPublicacion is not null or su.idPublicacion is not null) then "mixto"
  when s.idPublicacion is not null then "servicio"
    when v.idPublicacion is not null then "articulo"
    when su.idPublicacion is not null then "articulo"
END
as TipoPublicacion
from publicacion p
left join servicio s on s.idPublicacion = p.idPublicacion
left join venta v on v.idPublicacion = p.idPublicacion
left join subasta su on su.idPublicacion = p.idPublicacion
```

2.4.2. SQL de Compras

```
select c.idCompra, c.idUsuario as idUsuarioComprador, p.idUsuario as idUsuarioVendedor,
c.fecha, c.cantidad, c.idPublicacion, p.precio,
tp.costo, tp.porcentajeVenta, tp.nombre, ca.puntaje
from compra c
join publicacion p
on c.idPublicacion = p.idPublicacion
join tipo_de_publicacion tp
on p.idTipoDePublicacion = tp.idTipoPublicacion
join calificacion ca
on c.idCompra = ca.idCompra
```

2.4.3. SQL de Facturas

```
select f.idFactura, p.idUsuario, f.fecha, f.totalAPagar, p.idPublicacion, tp.nombre
from factura f
inner join corresponde c
on c.idFactura = f.idFactura
inner join publicacion p
on c.idPublicacion = p.idPublicacion
inner join tipo_de_publicacion tp
on tp.idTipoPublicacion = p.idTipoDePublicacion
```

2.5. Implementación MongoDB

Para implementar la base de datos de documentos en mongoDB utilizamos los JSON de las colecciones descriptos anteriormente y los importamos de la siguiente forma:

```
mongoimport --db tp2 --collection compras --drop --file ./compra_mongo.json
mongoimport --db tp2 --collection facturas --drop --file ./factura_mongo.json
mongoimport --db tp2 --collection publicacion --drop --file ./publicacion_mongo.json
```

3. Parte 2 - Map Reduce

3.1. Ejercicio 1

El importe total de ventas por usuario.

```
1 var ej1_m = function(){
2   emit(this.Publicacion.idUsuario, this.Publicacion.Precio * this.cantidad)
3 }
4
5 var ej1_r = function(k, vs){
6   return Array.sum(vs);
7 }
```

3.2. Ejercicio 2

La reputación histórica de cada usuario según la calificación.

```
1 var ej2_m = function(){
2   if(this.calificacionVendedor != null) emit(this.idUsuario, this.calificacionVendedor);
3   if(this.calificacionComprador != null) emit(this.Publicacion.idUsuario, this.calificacionComprador);
4 }
5
6 var ej2_r = function(k, vs){
7   return ( Array.sum(vs) / vs.length);
8 }
```

3.3. Ejercicio 3

Las operaciones con comisión más alta.

```
1 var ej3_m = function(){
2   var getComision = function(compra){
3     var subs = compra.Publicacion;
4     return (subs.Precio * compra.cantidad) * (subs.PorcentajeVenta / 100);
5   };
6
7   emit("todos", {
8     'idCompra': this.idCompra,
9     'comision': getComision(this)});
10 };
11
12 var ej3_r = function(k, vs){
13   var max = Math.max(...vs.map(function(v){
14     return v.comision;
15   }));
16   return {"resultado": vs.filter(function(v){
17     return v.comision >= max;
18   }), "max": max};
19 };
```

3.4. Ejercicio 4

El monto total facturado por año.

```
1 var ej4_m = function(){
2   var getAno = function(fecha){
3     return fecha.trim().substring(0,4);
4   }
5   emit(getAno(this.Fecha), this.TotalAPagar)
6 }
7
8 var ej4_r = function(k, vs){
9   return Array.sum(vs);
10 }
```

3.5. Ejercicio 5

El monto total facturado por año de las operaciones pertenecientes a usuarios con suscripciones Rubi Oriente.

```
1 var ej5_m1 = function(){
2
3   var esRuby = function(e, i, arr){
4     return e.TipoSuscripcion.trim() == "RubiDeOriente"
5   };
6
7   var getAno = function(fecha){
8     return fecha.trim().substring(0,4);
9   }
10
11   emit(
12     {
13       "ano": getAno(this.Fecha),
14       "usuario": this.IdUsuario
15     },
16     {
17       "totalAPagar": this.TotalAPagar,
18       "esRuby": this.estoyPagando.some(esRuby)
19     });
20 };
21
22 var ej5_r1 = function(k, vs){
23   if (vs.some(function(a){
24     return a.esRuby;
25   })))
26   {
27     return Array.sum(vs.map(function(e){return e.totalAPagar}));
28   }
29 }
30
31
32 var ej5_m2 = function(){
33   if (this.value.esRuby)
34   {
35     emit(this._id.ano, this.value.totalAPagar);
36   }
37 }
38
39 var ej5_r2 = function(k, vs){
40   return Array.sum(vs);
41 }
```

3.6. Ejercicio 6

El total de publicaciones por tipo de publicación (productos, servicios o mixtas).


```

1 var ej6_m = function(){
2   emit(this.TipoPublicacion, 1);
3 }
4
5 var ej6_r = function(k,vs){
6   return vs.length;
7 };

```

Listing 1: Ejercicio 6

4. Parte 3 - Sharding

4.1. Introducción

Utilizamos 5 shards para hacer las pruebas y a la colección de publicaciones le agregamos un atributo extra `idUsuarioVendedor` para poder usarlo como atributo clave a la hora de hacer experimentos de sharding. Cada 200000 insert hacemos un output en un archivo de

`db.publicaciones.getShardDistribution()` y `sh.status()` y con estos datos hicimos los gráficos.

4.2. Inserción de datos en la base de datos

Para insertar 500000 registros en la base de datos lo que hicimos fue generar un script en Python que nos devuelva 500000 publicaciones.

El pseudocodigo para la generación de los 500000 registros:

```

import json
from pprint import pprint
import random
from random import randint

foo = ['articulo', 'servicio', 'mixto']
print 'var pubs = ['
for x in range(1,500000):
    print '{'
    print '"idPublicacion":', x, ","
    print '"TipoPublicacion":', ", ", random.choice(foo), ","
    print '"idUsuarioVendedor":', randint(0,8000)
    print '},'
print ']'

```

A continuación, para insertar estos datos en la base de datos de mongo, hicimos un script de JavaScript para correrlo desde el Shell de mongo y que pueda importar todos estos datos en los distintos shards

```

1 var collection = "publicaciones";
2
3 pubs.forEach(function(e, i){
4   if (i % 20000 == 0){
5     db[collection].getShardDistribution();
6   }
7   db[collection].insert(e);
8 });

```

Listing 2: Ejercicio 6

5. Índice Simple

5.1. Creación de Shards

Para la creación de los Shards con Índice Simple corrimos los siguientes scripts:

Creamos los shards:

```
mkdir -p ./data/localhost10000
mongod --rest --shardsvr --port 10000 --dbpath data/localhost10000
--logpath data/localhost10000/log
```

```
mkdir -p ./data/localhost10001
mongod --rest --shardsvr --port 10001 --dbpath data/localhost10001
--logpath data/localhost10001/log
```

```
mkdir -p ./data/localhost10002
mongod --rest --shardsvr --port 10002 --dbpath data/localhost10002
--logpath data/localhost10002/log
```

```
mkdir -p ./data/localhost10003
mongod --rest --shardsvr --port 10003 --dbpath data/localhost10003
--logpath data/localhost10003/log
```

```
mkdir -p ./data/localhost10004
mongod --rest --shardsvr --port 10004 --dbpath data/localhost10004
--logpath data/localhost10004/log
```

Creamos el config server

```
mkdir -p ./data/localhost10005
mongod --rest --configsvr --port 10005 --dbpath data/localhost10005
--logpath data/localhost10005/log
```

Creemos routing service

```
mongos --port 10006 --configdb localhost:10005 > run_routing_service_log
```

Agregamos los shards

```
mongo localhost:10006
use admin
db.runCommand({addshard:"localhost:10000", name:"shard10000"});
db.runCommand({addshard:"localhost:10001", name:"shard10001"});
db.runCommand({addshard:"localhost:10002", name:"shard10002"});
db.runCommand({addshard:"localhost:10003", name:"shard10003"});
db.runCommand({addshard:"localhost:10004", name:"shard10004"});
```


Configuramos los Shards:

```
use test_sharding
sh.enableSharding("test_sharding")
db.people.ensureIndex({"zip": 1})
```

5.2. Evolucion de Shards

A continuación se muestra un cuadro donde se encuentran los datos obtenidos del análisis de los Shards. Lo que hicimos fue ver el `getShardDistribution()` cada 20000 inserciones y mostrar el porcentaje de distribución de los datos en los distintos Shards. Como ya fue explicado, utilizamos 5 Shards y en el cuadro se ve el porcentaje de datos que contiene cada Shard cada 20000 insert desde 0 hasta 500000 registros. Para este análisis utilizamos índices simples sobre la columna `idUsuarioVendedor` del documento de Publicaciones.

	Shard 0	Shard 1	Shard 2	Shard 3	Shard 4
20000	18566	12	1422	0	0
40000	10898	27	2895	16012	10168
60000	16399	33	4389	24017	15162
80000	21962	13045	5879	19014	20100
100000	27395	16295	7256	23916	25138
120000	18870	19565	22801	28630	30134
140000	22053	22790	26591	33464	35102
160000	25124	26010	30487	38234	40145
180000	28224	29276	34306	43027	45167
200000	31345	32547	38098	47838	50172
220000	34452	35822	41816	52637	55273
240000	37547	39089	45576	57523	60265
260000	40700	42449	49379	62116	65356
280000	43853	45730	53114	66861	70442
300000	46953	48882	56887	71705	75573
320000	50053	52090	60751	76535	80571
340000	53176	55353	64618	81312	85541
360000	56417	58495	68396	86047	90645
380000	59516	61838	72166	90935	95545
400000	80161	65164	75885	78202	100588
420000	84135	68400	79757	82031	105677
440000	105287	71633	83544	85904	93632
460000	110087	74902	87305	89798	97908
480000	114876	78190	91144	93638	102152
500000	119624	81454	94919	97576	106427



6. Indice Hash

6.1. Creacion de Shards

Para la creacion de los Shards con Indice Hash corrimos los siguientes scripts:

Creamos los shards:

```
mkdir -p ./data/localhost10000
mongod --rest --shardsvr --port 10000 --dbpath data/localhost10000
--logpath data/localhost10000/log
```

```
mkdir -p ./data/localhost10001
mongod --rest --shardsvr --port 10001 --dbpath data/localhost10001
--logpath data/localhost10001/log
```

```
mkdir -p ./data/localhost10002
mongod --rest --shardsvr --port 10002 --dbpath data/localhost10002
--logpath data/localhost10002/log
```

```
mkdir -p ./data/localhost10003
mongod --rest --shardsvr --port 10003 --dbpath data/localhost10003
--logpath data/localhost10003/log
```

```
mkdir -p ./data/localhost10004
mongod --rest --shardsvr --port 10004 --dbpath data/localhost10004
--logpath data/localhost10004/log
```

Creamos el config server

```
mkdir -p ./data/localhost10005
mongod --rest --configsvr --port 10005 --dbpath data/localhost10005
--logpath data/localhost10005/log
```

Creemos routing service

```
mongos --port 10006 --configdb localhost:10005 > run_routing_service_log
```

Agregamos los shards

```
mongo localhost:10006
use admin
db.runCommand({addshard:"localhost:10000", name:"shard10000"});
db.runCommand({addshard:"localhost:10001", name:"shard10001"});
db.runCommand({addshard:"localhost:10002", name:"shard10002"});
db.runCommand({addshard:"localhost:10003", name:"shard10003"});
db.runCommand({addshard:"localhost:10004", name:"shard10004"});
```


Configuramos los Shards:

```
use test_sharding
sh.enableSharding("test_sharding")
db.people.ensureIndex({"_id": "hashed"})
```

6.2. Evolución de Shards

A continuación se muestra un cuadro donde se encuentran los datos obtenidos del análisis de los Shards. Lo que hicimos, fue ver el `getShardDistribution()` cada 20000 inserciones y mostrar el porcentaje de distribución de los datos en los distintos Shards. Como ya fue explicado, utilizamos 5 Shards y en el cuadro se ve el porcentaje de datos que contiene cada Shard cada 20000 insert desde 0 hasta 500000 registros. Para este análisis utilizamos índices hash sobre la columna `idUsuarioVendedor` del documento de Publicaciones.

	Shard 0	Shard 1	Shard 2	Shard 3	Shard 4
20000	3970	3957	3934	4134	4005
40000	7979	7933	8018	7995	8075
60000	12000	11891	12002	12022	12085
80000	15999	15799	15993	16092	16117
100000	19968	19877	20008	20013	20134
120000	24017	23810	24072	24035	24066
140000	28113	27737	27992	28042	28116
160000	32055	31792	31936	32022	32195
180000	35999	35911	35940	35964	36186
200000	39889	39965	40000	39951	40195
220000	43965	44059	43872	43942	44162
240000	47961	48022	47859	48034	48124
260000	51904	52054	51932	52046	52064
280000	55854	56078	55858	56038	56172
300000	59820	60113	59859	60026	60182
320000	63791	64051	63867	64192	64099
340000	67683	68115	67831	68248	68123
360000	71707	72019	71812	72294	72168
380000	75701	76031	75853	76242	76173
400000	79715	80052	79889	80249	80095
420000	83766	83884	83915	84373	84062
440000	87698	87908	87984	88335	88075
460000	91684	91946	92108	92223	92039
480000	95652	96077	96045	96236	95990



7. Indice Simple vs Indice Hash

En el caso de shards utilizando indice hash se puede ver que la distribucion en caso de hash es casi ideal. A medida que se van agregando documento, van creciendo la cantidad de documentos en cada shard pero siempre cumpliendo una uniformidad. Mientras que en el caso de shards utilizando indices simples se puede ver que luego de la primera corrida casi el 100 % de la informacion esta en el shard numero 1. Luego se empiezan a utilizar los otros shard pero con una distribucion no tan regular, y se basa mas en la regularidad de los shards 1 a 4 y a medida que va creciendo la cantidad de documento se va regularizando.